




Berlin-Brandenburgische
AKADEMIE DER WISSENSCHAFTEN

TOPIC MODELING · JEAN PAUL'S LETTERS

TM Pipeline

Fernanda Wolff
TELOTA/BBAW



Digital Edition of Jean Paul's letters: *3 corpora*

Jean Paul – Sämtliche Briefe ↻ digital

Über die EditionBriefeRegisterDatenSuche

Jean Paul – Sämtliche Briefe ↻ digital

Herausgegeben im Auftrag der Berlin-Brandenburgischen Akademie der Wissenschaften von Markus Bernauer, Norbert Miller und Frederike Neuber (2018–2027).


Alle Briefe öffnen

Über die Edition

✉


Korpora

1



Briefe von Jean Paul

2



Briefe aus Jean Pauls Umfeld

3



Briefe an Jean Paul

- 1

Letters from Jean Paul
Briefe von Jean Paul
- 2

Letters from Jean Paul's surroundings
Briefe aus Jean Pauls Umfeld
- 3

Letters to Jean Paul
Briefe an Jean Paul

A letter in the edition

Von Jean Paul an Adam Lorenz von Oerthel. Hof, vor dem 11. Oktober 1780.

 Johann Paul Friedrich Richter  Adam Lorenz von Oerthel  Hof

Kritischer und kommentierter Text Lesetext

[Druck]

[Hof, vor 11. Okt. 1780]

1,2

Ach die wenigen Zeilen haben mir Thränen verursacht, mir — der wenig Freud' hat; denn wo wäre sie? — und der auch diese einigen bald missen mus. Wenn ich vielleicht weg bin: so seh' zu Nachts zu deinen Gängen in den Garten hin, wenn sie der Volmond beschimmert — und denke dan d'ran — wie wir ienseits hinüber über das beleuchtete Wasser blikten — wie eine freundschaftliche Thräne dem Aug' entdrang — zum Alvater hinauf — — Ach! die Tage der Kindheit sind hin — die Tage des Schülers bei beiden auch bald endet — bald's ganze Leben — — Hier kamst du und unterbrachst mich;

1,5

1,10

Textgrundlage

D: Jean Pauls Sämtliche Werke, Historisch-kritische Ausgabe. III. Abteilung, Band 1. Hrsg. v. Eduard Berend. Berlin: Akademie Verlag, 1956. Briefnr.: 1. Seite(n): 1 (Briefftext) und 416–417 (Kommentar). [Konkordanzen Druck-Digitale Edition >](#)

Kommentar (der gedruckten Ausgabe) [Siglen](#)

J: Wahrheit 3,62. 1, 5 seh'] sieh' (in diesen Jahren gebraucht Richter stets die schwache Imperativform, s. 84, 20, 98, 18, 145, 22) 16 senkest bis 21 zernagt.] in Anführungsstrichen, wohl versehentlich, denn es handelt sich sicher nicht um ein Zitat 22 Lese] Lies (vgl. 84, 13.29, 269, 25, 362, 28, 397, 37). Vielleicht schrieb Jean Paul Les, wie Bd. II, 4, 24.

Über Johann Adam Lorenz von Oerthel, geb. 17. April 1763 in Hof, gest. 13. Okt. 1786 in Töpen, den älteren Sohn des Kammerrats von Oerthel (s. Nr. 86†), seit 19. Sept. 1775 Schüler des Hofer

...and its TEI/XML source

```
1  <TEI xmlns="http://www.tei-c.org/ns/1.0" type="letter" xml:id="I_1">
2    <teiHeader>
3      <fileDesc>
4        <titleStmt>
5          <title n="print" rend="1">*1. An Adam Lorenz von Oerthel in Hof.</title>
6          <title n="digital">Von Jean Paul an Adam Lorenz von Oerthel. Hof, vor dem 11. Oktober 1780.</title>
7        <editor>
8          <persName xml:id="EB" ref="http://d-nb.info/gnd/118655795">
9            <surname>Berend</surname>
10           <forename>Eduard</forename>
11         </persName>
12       </editor>
13     <respStmt>
14       <resp>Editorische Bearbeitungen und Ergänzungen</resp>
15       <persName xml:id="MB" ref="http://d-nb.info/gnd/112754147">
16         <surname>Markus</surname>
17         <forename>Bernauer</forename>
18       </persName>
19     </respStmt>
20   <respStmt>
21     <resp>Konzeption und Entwicklung der digitalen Edition</resp>
22     <persName ref="http://d-nb.info/gnd/1121508855">
23       <surname>Neuber</surname>
24       <forename>Frederike</forename>
25     </persName>
26   </respStmt>
27 </respStmt>
28 <resp>Mitarbeit digitale Edition</resp>
29 <persName>
30   <surname>Klappenbach</surname>
31   <forename>Lou</forename>
32 </persName>
```

Workflow

1 Text input

from the TEI XML of the edition

2 Text preprocessing


removing XML markup, removing stop words, normalizing the language, generating corpora

3 Topic Modeling analysis


MALLET – LDA

4 Postprocessing

reconcile Topic Modeling results and the Texts of the edition;
results of the analysis are **not** detached from texts



(Henny-Krahmer/Neuber 2022/26)



Mockup of the Jean Paul – Sämtliche Briefe digital Topic Browser . Generated with Claude based on the Signs@40 Topic Modeling navigator (Goldstone et al, 2014).

Challenges



Source material in TEI/XML

- Annotated letters (editorial interventions, notes, named entities, ...)
- 3 different corpora with 3 (slightly) different schemas



Historical spelling (1770–1830 German)

bey Ihnen → *bei Ihnen*



Literary character of the texts


- Figures of speech: irony, metaphors, ...



Several topics per letter

- Letter writing; love; marriage; views on life...

Workflow: preprocessing



Technical Challenges



Modular architecture

- Better for future development: add or swap modules
- Better for reuse: organized containers, clearly defined responsibilities



Reproducibility (...?)

- Configurations and choices are persistent and documented



Transparency

- *Extensive documentation for usage and further development*



Low technical threshold

(for exploring the results)

- Running topic modeling requires understanding the method
- Analyzing the results requires cooperation with field experts

Tasks

STAGE	TASKS	COMPONENTS → TOOLS
pre-preprocessing	What to extract from XML/TEI	
preprocessing	Prepare Text Normalize spelling? · Lemmatize? · Keep Named Entities? · Select Parts of Speech?	Content ExtractionTEI/XML (json, txt...) NormalizationTransnormer, CAB, ... Linguistic ProcessingSpacy
modeling	Run Topic Modeling LDA? · BERTopic?	Modeling EngineMALLET, BERTopic
dashboard	Explore the Results Does it make sense? · Which labels? · Which model?	
postprocessing	Embed (back) into XML/TEI	

Design



Base

CLI tool for running topic modeling + a dashboard for exploring results



Further Development

Added UI (based on streamlit); the whole pipeline can be controlled through the UI

Topic Modelling

Guided pipeline runs, trained-model comparison, and project documentation.

 Documentation

Pipeline architecture and usage docs (Quarto site, requires BBAW login).

 Element Discovery

guided form to build to discover and configure elements which will be stripped in the preprocessing step.

 Run Pipeline

Build a config and launch a preprocessing or modeling run.

 Dashboard

Browse and compare trained topic models. Requires at least one modeling run.